

LLM Alignment

בונים ומיישרים עוזר מתוך מודל יסוד

מטלה מספר 2 | מודלי יסוד: ארכיטקטורות, אימון ויישור

תאריך פרסום	26 באוגוסט 2026	מועד הגשה	מוגדר במודל.
אופן העבודה	אישית	משקל בציון הקורס	כמוגדר בדף המידע.
פורמט הגשה	Notebook הרץ מתחילתו ועד סופו (Google Colab / Jupyter) + דו"ח PDF קצר (5–7 עמודים, לא כולל נספחים) + קובץ requirements / תא כותרת עם גרסאות ספריות + README קצר		
סביבת חישוב	Colab Pro בלבד (לא Pro+/Enterprise) — GPU יחיד, מכסת compute units חודשית מוגבלת, ומגבלת session. זהו אילוף מחייב בתכנון הניסויים — ר' תיבת "אילוצי חישוב" בהמשך.		

רקע ומטרה

במטלה 1 חקרתם מודלים קיימים כ"קופסה שחורה" — טוקניזציה, דקודינג, קונטקסט, יעילות ותקלות — בלי לגעת באימון עצמו. במטלה הזו אתם עוברים מצד הצופה לצד הבונה: תאמנו ותיישרו בעצמכם מודל יסוד קטן, ותתעדו אמפירית כיצד כל שלב באימון (SFT, PEFT, בניית דאטת העדפות, DPO, Best-of-N) משנה בפועל את התנהגות המודל. בדיוק כפי שנכתב במטלה 1 — אימון וכיוונון הם הנושאים ש"יפיעו בהמשך הקורס". זה ההמשך הזה.

כמו במטלה 1, הדגש הוא על **עיצוב ניסוי מבוקר, מדידה כמותית, והסקת מסקנות מכיליות** — לא על "איזה מודל הכי טוב". בניגוד למטלה 1, הפעם תשתמשו בכלי הערכה אוטומטי — **LLM-as-a-Judge** — כדי לנקד תוצאות בקנה מידה שאי אפשר להשיג בתיג ידני. השימוש בכלי הזה מחייב זהירות מתודולוגית, ותידרשו להראות שאתם מודעים למגבלותיו (ר' נספח ב').

אילוצי חישוב — Colab Pro (קריאה חובה לפני תחילת העבודה)

Colab Pro נותן GPU יחיד (בהתאם לזמינות: T4 / L4 / A100), מכסת compute units חודשית סופית (לא בלתי מוגבלת), ומגבלת אורך session. תכננו את הניסויים כך שכל חלקי המטלה יחד ייכנסו בתקציב הזה:

Full fine-tuning — עד כ-0.5B–1B פרמטרים (למשל Qwen2.5-0.5B-base, SmolLM2-360M/1.7B-base) (base).

LoRA / QLoRA — עד כ-3B פרמטרים לחלקים הנדרשים (Llama-3.2-3B, Qwen2.5-1.5B/3B-base, Gemma-2-2b). מודלים עד כ-7B עם QLoRA מותרים רק בבנוס האופציונלי.

בכל חלק: דאטהסטים קטנים (אלפים בודדים של דוגמאות), 1–3 epochs — המטרה היא להראות מגמה מדידה, לא לאמן מודל production.

השתמשו באותה משפחת מודל בסיס בחלקים A–F כדי שההשוואות תהיינה תקפות.

אם נתקעתם בתקרת זיכרון/זמן — מותר לצמצם את גודל הדאטה או מספר החזרות (repeats), אך לא לדלג על העיקרון שהניסוי אמור להדגים.

מודל בסיס ודאטה

- בחרו מודל base פתוח (לא גרסת instruct) ממשפחה כגון Qwen2.5, SmolLM2, Gemma-2, Llama-3.2, הניתן לטעינה מ-Hugging Face.
- בחרו דאטהסט הוראות פתוח (למשל Alpaca, Dolly-15k, UltraChat, OpenAssistant/OASST) ודאטהסט העדפות פתוח (למשל Anthropic HH, HH-RLHF, UltraFeedback) — או בנו דאטת העדפות בעצמכם בחלק ד' באמצעות LLM-as-a-Judge.
- תעדו במדויק: שם/revision/dtype של המודל, גודל וגרסת כל דאטהסט, וכל היפר-פרמטר (LR, batch size, epochs, rank של LoRA וכו').

- אין צורך במודל מסחרי בתשלום עבור המודל המאומן. לתפקיד ה-Judge מותר להשתמש גם ב-API מסחרי אם יש לכם גישה, ובלבד שהוא ממשפחה שונה מהמודל המאומן (ר' נספח ב').

חלק א' — SFT בסיסי: בניית עוזר מ-Base Model

1. בחרו מודל base קטן ופתוח ותעדו את זהותו המדויקת.
 2. בחרו תת-קבוצה מדאטהסט הוראות (כ-2,000–5,000 דוגמאות, בהתאם לתקציב).
 3. בצעו full fine-tuning על תת-הקבוצה.
 4. הגדירו סט קבוע של לפחות 10 פרומפטים (יישמר קבוע לאורך כל שאר המטלה) ובדקו את תגובות המודל לפני ואחרי ה-SFT.
- שאלת ניתוח:** אילו סוגי שינויים התנהגותיים אתם מבחינים (עקביות פורמט, נכונות ל"עקוב אחר הוראה", טון, אורך תשובה)? האם יש עדות להתאמת-יתר (overfitting) לדאטהסט הקטן (למשל שינון במקום הכללה)?

חלק ב' — PEFT: Full Fine-Tuning מול LoRA מול QLoRA

5. חזרו על אותו אימון בדיוק (אותו דאטהסט, אותו מספר epochs) עם LoRA, ולאחר מכן עם QLoRA, על אותו מודל בסיס מחלק א'.
 6. עבור כל אחת משלוש השיטות (Full FT מחלק א', QLoRA, LoRA) מדדו: מספר פרמטרים לאימון (וכאחוז מסך הפרמטרים), זיכרון GPU בזמן אימון (peak), זמן אימון כולל.
 7. נקדו איכות פלט על סט הפרומפטים הקבוע באמצעות LLM-as-a-Judge בהשוואה זוגית מול הבייסליין הלא-מכוון (ר' נספח ב' להנחיות המחייבות).
- שאלת ניתוח:** האם יש טרייד-אוף בין חיסכון במשאבים לאיכות? האם ה-quantization ב-QLoRA פגע בביצועים בצורה שנמדדה בפועל, או שההבדל בטווח הרעש?

חלק ג' — אבליציה על גודל/איכות דאטת האימון

8. בחרו את השיטה היעילה ביותר מחלק ב' (סביר שזו LoRA) וחזרו על האימון בשתי תצורות דאטה נוספות: subset (1) קטן מאוד (כ-200 דוגמאות), subset (2) עם דוגמאות "רועשות"/באיכות ירודה בכוונה (למשל תשובות לא רלוונטיות או שגויות שהוזרקו בכוונה).
 9. נקדו כל תצורה מול הבייסליין מחלק א' באמצעות אותה שיטת LLM-as-a-Judge.
- שאלת ניתוח:** כיצד גודל/איכות דאטת ה-SFT משפיעים על ההתנהגות הנצפית? האם התוצאות תואמות את האינטואיציה מהקורס לגבי scale (יותר/יותר-נקי תמיד עדיף), או שראיתם חריגה?

חלק ד' — דאטת העדפות ובניית Reward Model

10. הפיקו לפחות 2 תגובות שונות (למשל בטמפרטורות/אסטרטגיות דקודינג שונות) מהמודל המכוון (מחלק א'/'ב') על לפחות 30 פרומפטים חדשים (לא מסט חלק א').
 11. השתמשו ב-LLM-as-a-Judge (pairwise) כדי לתייג chosen/rejected על כל זוג, לפי ההנחיות המחייבות בנספח ב' (judge ממשפחה שונה, ממוצע דו-כיווני).
 12. אמנו reward model קל-משקל על דאטת ההעדפות שנוצרה (ראש רגרסיה מעל embeddings של המודל, או ספרייט ייעודית כגון TRL).
 13. עבור מדגם של כ-20 זוגות, שרטטו את הקשר בין הפרש ה-reward המשוער (מהמודל שאימנתם) לבין תווית ההעדפה שנקבעה — תיאור בלבד, ללא צורך בגזירה מתמטית.
- שאלת ניתוח:** היכן ראיתם עדות להטיה של ה-judge (position bias, verbosity bias, self-enhancement)? אילו זוגות "מפוקפקים" (borderline) מצאתם, ואיך הייתם מטפלים בהם בפרויקט אמיתי?

חלק ה' — יישור העדפות באמצעות DPO

14. אמנו DPO על מודל ה-SFT/LoRA (מחלק א'ב') באמצעות דאטת ההעדפות מחלק ד'.
 15. השוו את התנהגות המודל לפני DPO (בייסליין SFT) מול אחרי DPO, על סט הפרומפטים הקבוע מחלק א', באמצעות LLM-as-a-Judge (win-rate + tie-rate).
שאלת ניתוח: האם השיפור שנמדד משכנע בעיניכם? האם יש חשד למעגליות — שהמודל "למד לרצות את השופט" ולא בהכרח השתפר במובן רחב יותר? איך הייתם בודקים זאת בלי משאבים נוספים (למשל judge שונה, בדיקה אנושית קטנה)?

חלק ו' — Best-of-N כאלטרנטיבה קלה יותר

16. הריצו Best-of-N (למשל N=4 ו-N=8) בזמן אינפרנס על מודל ה-SFT (ללא אימון נוסף), עם ה-reward model מחלק ד' לדירוג המועמדים.
 17. השוו: איכות (win-rate מול בייסליין SFT, אותו judge) ועלות חישובית (זמן/טוקנים לכל שאילתה) — מול מודל ה-DPO מחלק ה'.
שאלת ניתוח: מתי הייתם ממליצים על Best-of-N במקום DPO בסביבת production, ולהפך? מה קורה ליתרון ה-BoN כש-N גדל?

סינתזה מסכמת — "פרופיל אימון ויישור" (עמוד אחד)

- כתבו עמוד סיכום הכולל:
 18. טבלה מסכמת: שיטה (Full FT / LoRA / QLoRA / DPO / BoN) מול מדדים (איכות לפי judge, זמן אימון, זיכרון, עלות אינפרנס).
 19. מה השתפר בוודאות סבירה, ומה תלוי-judge ולכן פחות ודאי.
 20. המלצה מנומקת: איזו שיטה הייתם בוחרים לפרודקשן בתקציב חישוב מוגבל כמו זה שהיה לכם, ולמה.

בונוס (עד 5 נקודות, בחרו אפשרות אחת בלבד)

21. ריצת PPO/RLHF זעיר-קנה-מידה (למשל דרך TRL PPOTrainer) על אותו מודל, והשוואה מול תוצאות ה-DPO מחלק ה'.
 22. DPO איטרטיבי — 2–3 סבבים, כאשר בכל סבב דאטת ההעדפות מעודכנת מפלטי המודל מהסבב הקודם.
 23. אבלציה על מיקום שכבות ה-LoRA (attention-only מול all-linear) והשפעתה על איכות מול מספר פרמטרים.
 24. בדיקת עמידות ה-judge עצמו: הריצו את אותו judge פעמיים על אותם זוגות בסדר הפוך, ומדדו את ה-agreement — עדות כמותית ל-position bias בפועל.
 25. QLoRA על מודל גדול יותר (עד כ-7B) והשוואת התוצאה למודל ה-3B מהחלקים העיקריים.

נספח א' — דרישות שחזוריות (Reproducibility)

- תעדו לכל ריצה: מזהה מדויק של המודל (name/revision), dtype, וכל היפר-פרמטר רלוונטי.
- קבעו וקבעו (seed) בכל מקום שיש דגימה אקראית, ותעדו אותו.
- אין להסתמך על ריצה בודדת כאשר קיים רעש משמעותי (למשל win-rate על מדגם קטן) - חזרו על מדידות רועשות לפחות פעמיים.
- לכל גרף/טבלה — כותרת ברורה, תיוג צירים, ומקרא.
- הפרידו באופן ברור בדו"ח בין תוצאה אמפירית, פרשנות, וספקולציה.

נספח ב' — הנחיות מחייבות לשימוש ב-LLM-as-a-Judge

ה-judge חייב להיות ממשפחת מודלים שונה מהמודל שמאמנים/מעריכים (למשל אם המודל הנבדק הוא Qwen — ה-judge יכול להיות Llama, Gemma, או מודל API).
 פלט ה-judge חייב לכלול נימוק (**rationale**) לפני הציון — לא ציון בלבד.
 לכל השוואה זוגית, חשבו ממוצע על **שני סדרי הצגה** (A מול B, ואז B מול A) כדי לנטרל position bias. אם הסדר משנה את התוצאה — דווחו זאת כ-tie או כחסר עקביות, אל תבחרו את הכיוון הנוח.
 דווחו לא רק win-rate אלא גם tie-rate, ואל תנפחו מסקנות מהפרשים קטנים (לדוגמה הפרש של 2 מתוך 10 השוואות אינו מובהק).
 תעדו את הפרומפט המדויק ששימש כ-judge (כולל תבנית הפלט/schema אם השתמשתם ב-structured output).
 בכל מקום שבו judge משמש גם ליצירת דאטת אימון (חלק ד') וגם למדידת הצלחה (חלק ה'/ו'), חובה לציין זאת בדו"ח כמגבלה מתודולוגית מפורשת.

מדיניות כלי AI

מותר להשתמש בכלי AI לצורכי תכנות, debugging ושיפור ניסוח, אך האחריות להבנת הקוד, הניסויים והמסקנות היא שלכם — בדיוק כמו במטלה 1.

רשימת בדיקה להגשה

- ☐ Notebook שרץ מתחילתו ועד סופו ללא שגיאות
- ☐ דו"ח PDF בן 5–7 עמודים (לא כולל נספחים)
- ☐ תיעוד מדויק של מודל/גרסה/dtype לכל ריצה
- ☐ seed מתועד בכל מקום עם דגימה אקראית
- ☐ קובץ requirements / תא גרסאות ספריות
- ☐ README קצר עם הוראות הרצה, שמות מודלים ודרישות חומרה
- ☐ נספח עם פלטים גולמיים מלאים (אופציונלי אך מומלץ)

מחווני ציון

קטגוריה	משקל	מה נבדק
עיצוב ניסוי ומתודולוגיה	20%	בקרת משתנים, גודל מדגם סביר, שימוש נכון ב-LLM-as-a-Judge
ביצוע טכני	20%	קוד עובד, ניצול נכון של תקציב Colab Pro, תיעוד היפר-פרמטרים
ניסוי נושאי הקורס	20%	SFT, PEFT (LoRA/QLoRA), preference data, DPO, BoN
ניתוח והסקת מסקנות	25%	מסקנות מכוילות, זיהוי מגבלות (במיוחד מעגליות ה-judge), פרשנות מול ספקולציה
איכות דו"ח והצגה	15%	בהירות, גרפים מתוגלים, מבנה

בהצלחה! המשך ישיר לרוח מטלה 1 — הפעם לא רק בודקים מודל, בונים אחד.